



Projeto Integrado Feature Engineering

ANDERSON DA SILVA RAMOS RM359601

ARTHUR EYNG RM359484

IVAN CARLOS GAZIN RM359250

PAULO VINICIUS DE SOUZA KELLER RM359200

O Desafio




- Construir um modelo que garanta equilíbrio entre aprovação e segurança financeira.
- Em um cenário competitivo de concessão de crédito, precisávamos identificar **clientes inadimplentes** com mais precisão.
- Base de dados real, **desbalanceada**.
- Variáveis brutas, **sem preparação**.
- Mitigar o risco de concessão de cartões de crédito para mal pagadores.

As Dificuldades Iniciais

- Primeiro teste:**

- Rodamos inicialmente o modelo **Scikit Learn LogisticRegression** com o mínimo de ajuste na base de dados e os resultados foram péssimos. **Recall = 0.00** para a classe 1.0

	precision	recall	f1-score	support
0	0.74	1.00	0.85	11132
1	0.00	0.00	0.00	3868
accuracy			0.74	15000
macro avg	0.37	0.50	0.43	15000
weighted avg	0.55	0.74	0.63	15000



- Critério de avaliação:**

- Recall da variável target = 1:** pois prioriza identificar todos os potenciais inadimplentes, minimizando o risco de conceder cartão de crédito a maus pagadores e, conseqüentemente, as perdas financeiras. Em cenários de alto desbalanceamento e foco em evitar falsos negativos, ele se torna a métrica mais relevante para otimizar o modelo.

- Problemas Identificados:**


- Classe Target desbalanceada (inadimplentes eram minoritários).
- Outliers em variáveis contínuas (Renda, Idade, Quantidade de Dependentes).
- Features irrelevantes para o modelo (ID, Datas, Cidades, Estados etc...)
- Features com valores únicos

Tentativa de melhoria

- **Tratamento base de dados:**
 - Remoção das features não relevantes (Análise descritiva);
 - Tratamento de outliers da variável (Quantidade de Dependentes);
 - Preenchimento dos valores nulos utilizando KNN para as features.
 - Conversão e padronização de tipos de variáveis (Standard Scaler).

- **Segundo teste:**
 - Rodamos novamente o modelo **LogisticRegression** depois dos ajustes na base e novamente os resultados foram ruins, **Recall = 0.00** para a classe 1.0


	precision	recall	f1-score	support
0	0.74	1.00	0.85	11132
1	0.00	0.00	0.00	3868
accuracy			0.74	15000
macro avg	0.37	0.50	0.43	15000
weighted avg	0.55	0.74	0.63	15000



Melhor ajuste

• Pipeline de ajustes da base de dados:


- **Feature Engineering:** nova feature com o log de “Renda Total”, nova feature com a renda média por dependentes “Renda Total” / “Quant Dependentes”, nova feature multiplicando a “Idade” x “Renda Total”, feature “Idade” foi categorizada em ranges, criação da feature binária “Tem cartão” combinando as colunas “FLAG_X”
- **KNN e Simple Imputer:** Preenchimento variáveis faltantes
- **One Hot Encode:** transforma variáveis categóricas em colunas binárias para cada categoria “Dumificação”;
- **StandardScaler:** padroniza as features, escalando para um desvio padrão unitário.
- **Smote:** Balanceamento da classe minoritária da variável target;
- **Select K Best:** Seleção das features preditoras mais relevantes para o modelo;



• Terceiro teste:

- Rodamos novamente o modelo **LogisticRegression** depois dos ajustes e desta vez os resultados foram bastante promissores, **Recall = 0.62** para a classe 1

	precision	recall	f1-score	support
Classe 0	0.79	0.49	0.60	11147
Classe 1	0.30	0.62	0.40	3834
accuracy			0.52	14981
macro avg	0.54	0.56	0.50	14981
weighted avg	0.66	0.52	0.55	14981



Importância das Variáveis (em %):

	Feature	Importance (%)	Importance
0	ESTADO_CIVIL_1	100.000000	0.185411
6	IDADE_CAT_18-30	86.524209	0.083474
3	ESTADO_CIVIL_4	80.153703	0.035285
1	ESTADO_CIVIL_2	73.231045	-0.017081
7	IDADE_CAT_31-45	62.071953	-0.101494
4	TIPO_OCUPACAO_1.0	59.312803	-0.122365
2	ESTADO_CIVIL_3	50.453134	-0.189384
5	TEM_CARTAO_True	47.513610	-0.211620
8	IDADE_CAT_46-60	25.090286	-0.381240
9	IDADE_CAT_61-80	0.000000	-0.571034

Resultados

- **Resultado Final:**

- Modelo otimizado para atender o problema de negócios: não liberar cartão de crédito para pessoas com potencial de inadimplência.

- **Lições:**

- Feature Engineering é fundamental para a melhora dos resultados.
- O balanceamento adequado das features faz toda diferença em classificadores.
- Ajustes finos (fine-tuning) nos Hiperparâmetros do modelo melhoram a qualidade das previsões.
- Focar os ajustes observando o indicador correto no Classification Report para adequar os resultados do modelo ao problema de negócio, em no nosso caso este indicador foi o Recall para a variável target = 1, ou seja quando a pessoa é inadimplente.

- **Conclusão**

- Embora o modelo não tenha uma acurácia geral muito alta ele possui um Recall satisfatório para prever clientes com potencial de inadimplência.

Bônus - XGBoost XGBClassifier

- Embora não tenha sido solicitado, executamos por curiosidade o **XGBoost XGBClassifier** com os hiperparâmetros ajustados, o resultado obtido foi um pouco melhor, **68%** contra **62%** do **LogisticRegression**:



- Hiperparâmetros Ajustados:**

- Aplicação de **GridSearchCV** para buscar a melhor combinação:
 - Profundidade da árvore (max_depth);
 - Taxa de aprendizado (learning_rate);
 - Número de árvores (n_estimators);
 - Balanceamento (scale_pos_weight);

- Quarto Teste:**

- Usando **XGBoost XGBClassifier** o Recall obtido foi de **68%**, um pouco melhor que o **LogisticRegression** onde o melhor resultado foi **62%**.

	precision	recall	f1-score	support
0.0	0.80	0.44	0.57	11149
1.0	0.29	0.68	0.41	3851
accuracy			0.50	15000
macro avg	0.55	0.56	0.49	15000
weighted avg	0.67	0.50	0.53	15000



WALL ST

OBRIGADO